

「제5회 고용노동 공공데이터·AI 활용 공모전」아이디어 제안서

아이디어명

WageGuard — 공공 마이크로데이터·AI 기반 이주노동자 임금 착취 선제 탐지·점검 우선순위 제안 시스템

(부제: 신고 이전 단계의 노동감독·지원 자원 배분을 위한 위험 스코어링 및 대시보드)

[한눈에 보는 작품작 요약]

항목	내용
출품 부문	아이디어 기획 부문
팀명 / 대표	WageGuard / 김태성 (1인 출품)
핵심 가치	E9 근로자 66%가 자신의 계약 내용을 모르는 구조 — 신고할 수 없는 피해자를 국가가 먼저 찾아가도록 점검 우선순위를 데이터로 제안
핵심 활용 공공데이터	한국고용정보원(주관): 외국인근로자 근무현황·EIS·워크피디아 임금분포 / 고용노동부(주최): 임금체불 명단·근로사건·고용형태별근로실태조사·노동포털·최저임금 / 통계청 MDIS(보조)
활용 AI 기술	시계열 미세 변화 감지 특수 AI(Liquid Neural Network) + 다각도 이상 진단 앙상블(XGBoost·LSTM·PyOD) — 사업장·산업·시간 축의 위반 신호를 통합 스코어링
가점 항목 부합	(나) 주관기관(한국고용정보원) 데이터 활용(2점) ✓ / (가) 국가중점데이터 활용 가능(2점) / (라) 예비창업자 해당 시(1점)
실증 상태	491만 6,667건 학습 / XGBoost AUROC 0.9998, LNN 조기 AUROC 0.9957 / 코드·대시보드 작동
외부 검증	임금체불 명단·근로사건 매칭 → Precision@K / Recall@K 정량 보고 (파이프라인 내장)
코드 저장소	https://github.com/kts6450/WageGuard

1) 아이디어 구상 및 제안 배경

1-1. 사회 문제

- E9(비전문취업) 비자 근로자의 약 66%가 자신의 근로계약 내용을 인지하지 못한다(통계청 이민자체류실태조사). 계약을 모르는 사람은 위반도 인식하지 못하고, 인식하지 못하면 신고도 하지 않는다. 이것이 이주노동자 임금 착취 신고율이 5% 미만에 그치는 구조적 이유다.
- 국내 이주노동자는 약 90만 명(고용노동부, 2024)이며, 제조·농축산·건설·돌봄 영역에 집중되어 있다. 임금 체불·삭감·과도한 공제·초과근무 미지급 등 착취형 위반은 광범위하게 발생하지만 피해자가 신고에 도달하지 못하는 이유는 다음과 같다.
- 언어 장벽으로 인한 신고 절차 접근성 부족
- 체류 자격(비자) 취소 위험에 대한 두려움
- 근로감독관 1인당 담당 사업장 수천 개의 구조적 자원 한계

1-2. 기존 접근의 한계

구분	한계
신고 기반 사후 대응	피해자 자력 신고에 의존 → 가장 취약한 이주노동자가 가장 적게 신고
단순 통계 보고서	산업·연도 단위 거시 추이 중심 → 현장 점검 우선순위로 환원되지 않음
기존 부정수급 탐지	사업주 행정 데이터 위주 → 임금·근로조건 위반의 미시 패턴 미반영

1-3. 왜 지금 이 시스템이 필요한가

최근 고용노동부의 핵심 정책 방향은 노동 약자 보호와 미조직 근로자 지원이다. 두 가지 모두 신고 통로가 없거나 신고를 두려워하는 노동자에게 국가가 먼저 다가가야 한다는 점에서 출발한다. 다만 현장에서 이 방향을 실현하려면 "누구를 먼저 찾아가 할 것인가"를 데이터로 답하는 도구가 필요하다.

이주노동자는 노동 약자와 미조직 근로자가 가장 짙게 겹치는 집단이다. WageGuard는 공공데이터와 AI를 결합해 그 답을 정량적으로 제시하는 시스템으로, AI를 단순 효율화 도구가 아니라 행정의 사각지대를 좁히는 보조 인프라로 활용한다.

1-4. 제안

본 아이디어 **WageGuard**는 고용노동부·한국고용정보원의 공공데이터와 통계청 마이크로데이터를 입력으로 받는 **AI 위험 스코어링**을 통해, 신고 이전에도 **고위험 사업장·고용형태·산업 클러스터의 점검 우선순위**를 도출한다. 결과는 자동 처벌이 아닌 **근로감독·지원 자원의 배분 보조**로 사용된다.

2) 아이디어의 고용노동 데이터 활용 방안(활용성)

2-1. 활용하는 고용노동 공공데이터 (제공기관·데이터명)

A. 핵심 데이터 — 주최·주관 기관 공공데이터

아래 10개 데이터는 각각 독립적으로도 의미가 있지만, 함께 쓸 때 "누가 위험한가(임금·근로 기준 위반)", "그 중 이주노동자 비중이 높은 곳은 어디인가(외국인 노출 가중치)", "모델이 실제로 맞는가(외부 그라운드 트루스)"라는 세 질문에 동시에 답할 수 있어 결합했다.

#	데이터명	제공기관 (구분)	본 아이디어에서의 활용
1	외국인근로자 근무현황(대상별 현황) data.go.kr	한국고용정보원(주관)	이주노동자 노출 가중치: 산업×지역×체류자격별 외국인 근로자 비중을 위험 점수에 결합 → 이주노동자 표적성 회복
2	임금체불 사업주 명단공개 moel.go.kr	고용노동부(주최)	외부 그라운드 트루스: 라벨 검증·Precision@K 보고에 사용
3	연도별 근로사건 현황 data.go.kr	고용노동부(주최)	노동관계법 위반 신고·처리 추세로 모델 출력의 정합성 검증
4	임금체불 통계(노동포털) labor.moel.go.kr	고용노동부(주최)	업종·규모별 체불액 시계열로 거시 검증
5	(노동통계) 고용형태별근로실태조사 — 공공데이터포털 개방판 data.go.kr	고용노동부(주최)	임금·근로시간·고용형태의 공식 개방 데이터 — 라벨링 본 데이터
6	EIS 고용행정통계 eis.work24.go.kr	한국고용정보원(주관)	사업장 규모·지역·연령·성별 피보험자, 구인·구직 등 노출 보정
7	워크피디아 임금체계 통계 wagework.go.kr	한국고용정보원(주관)	직종 표준 임금 분포(연봉제·호봉제 등) 대비 이상 신호 — 보조 라벨
8	고용노동통계정보시스템 laborstat.moel.go.kr	고용노동부(주최)	산업·고용형태·임금 거시 분포 검증
9	최저임금위원회 minimumwage.go.kr	고용노동부(주최)	연도별 법정 최저임금 — 라벨 정의 근거
10	외국인고용관리시스템(EPS) eps.go.kr	한국고용정보원(주관)	이주노동 정책·서비스 연계 시나리오

본 아이디어는 위 표의 데이터를 주 데이터(Primary)로 사용한다.

특히 #1 외국인근로자 근무현황, #6 EIS, #7 워크피디아는 주관기관(한국장애인고용공단·한국고용정보원) 중 한국고용정보원 공공데이터로, 공모전 안내의 가점 항목 "나" (주관기관 공공데이터 활용 시 가점 2점) 요건에 부합한다.

B. 보조 데이터 — 통계청 MDIS 마이크로데이터 (심층 라벨링·이주노동자 보정)

데이터명	제공기관	규모	본 아이디어에서의 활용
고용형태별근로실태조사 (2020~2024) MDIS	통계청 / 고용노동부	약 491만 건	4대보험·시간당임금·초과근무 변수 → 세부 라벨·XGBoost 학습 (개방판과 변수 정합)
이민자체류실태 및 고용조사 — 공통항목	통계청	약 12만 건	외국인 차별·소득 불만족 → 취약성 가중치
이민자체류실태 및 고용조사 — 비전문취업(E9) 부가항목	통계청	약 1.1만 건	계약 미인지율·이직 → 이주노동자 위험 보정
근로환경조사	통계청 / 한국산업안전보건공단	약 10만 건	폭력·괴롭힘·차별 등 근로환경 위험 보강

MDIS는 동일 조사의 마이크로데이터 버전으로, A의 고용형태별근로실태조사 개방판과 변수 정합이 유지된다. 개인 식별 변수는 사용하지 않으며 비밀유지 서약을 준수한다.

2-2. 타 기관·민간 데이터 (연계 계획)

- **공공데이터포털(data.go.kr)**: 사업장 인허가·산업 분류 등 메타데이터, 공공기관 위반 공시.
- **국세청·국민건강보험공단(개방 통계)**: 사업장 단위 4대보험 가입 추세(공개 통계 범위 내).
- **민간 보강(선택)**: 사업장 채용공고 텍스트·근로조건 표기 등 — **출처 명시·이용약관 준수** 전제.

2-3. 데이터 획득의 지속성, 활용범위, 가공 가능성

- **지속성**:
 - 고용노동부 임금체불 명단·근로사건 현황·노동포털 통계는 연(또는 월) 단위 정기 공표.
 - 한국고용정보원 EIS·워크피디아·외국인근로자 근무현황 또한 정기 갱신.
 - 통계청 MDIS 마이크로데이터도 매년 갱신.
 - 본 시스템은 동일 파이프라인을 연 단위로 재실행하여 자동 갱신할 수 있다.
- **활용범위**: 사업장·산업·지역·고용형태·체류자격 단위까지 결합 가능. **개인 식별 정보 없음**.
- **가공 가능성**:
 - **법정 기준 라벨**(4대보험·최저임금·초과근무) — `utils/real_data_processor.py` 에서 변수 결합으로 재현.
 - **외부 검증 라벨**: 임금체불 명단·근로사건 현황 매칭 → **Precision@K, Recall@K** 산출.
 - **직종 표준 라벨**: 워크피디아 임금 분포 P25 미만 등 **보조 라벨**.
 - **이주노동자 가중치**: 외국인근로자 근무현황으로 **산업×지역×체류자격 가중치** 부여.

2-4. 가점 항목 부합 (공모 안내 기준)

- 가점 “나” — 주관기관(한국장애인고용공단·한국고용정보원) 공공데이터 활용 시 2점 → 본 출품작은 **한국고용정보원** 공공 데이터인 **외국인근로자 근무현황·EIS·워크피디아** 직접 활용으로 **요건 충족**.
- 가점 “가” — 주최·주관·후원기관이 제공하는 **국가중점데이터** 활용 → 임금체불 명단 등 **국가중점데이터 목록**에 포함되는 항목이 있을 경우 동시에 충족 가능(가점 상한 2점).
- 가점 “라” — 아이디어 부문 **예비창업자**(공고일 기준 사업자등록 없음) 해당 시 1점.

2-5. 윤리·법적 고려

- 비식별 공공 통계만 사용. 임금체불 **사업주 명단**은 고용노동부의 **공식 공개 정보**만 활용하며, 모델 학습용으로 사용하더라도 **사후 인간 검토** 단계 이전에는 정책 처분에 사용하지 않는다.
- MDIS 이용약관·비밀유지 서약 준수.
- 결과는 **점점 우선순위 제안**에 한정하며, **자동 처벌 금지** 원칙을 시스템·UI 단계에서 명시한다.

3) 아이디어의 AI 활용 방안(활용성)

[비전공자용 한 줄 설명] WageGuard의 AI는 ① **횡단면 진단**(많은 사업장을 동시에 비교해 위험 사업장을 골라내는 모델), ② **시계열 조기 경보**(임금 지급 패턴의 미세한 변화에서 사전 신호를 잡는 특수 AI), ③ **이상 패턴 감지 앙상블**(여러 진단법을 합쳐 놓치는 신호를 줄임), ④ **이주노동자 가중치**(외국인 비중 높은 곳에 더 민감하게 반응) — 이 네 가지를 결합한 **통합 위험 진단 모델**이다. 아래 표는 전공자·기술 검증용 정확 명칭이다.

3-1. 활용 AI 기술 (적용 모델·라이브러리)

분류	기술	라이브러리	본 아이디어에서의 역할
그래디언트 부스팅 분류	XGBoost	xgboost	횡단면 변수 기반 착취 위험 확률 추정 (사업장·응답 단위)
시계열 딥러닝	Liquid Neural Network(LNN, CfC)	PyTorch + ncps	불규칙 시계열 (임금 지급 지연·간헐성)에서 조기 신호 학습
시계열 베이스라인	LSTM	PyTorch	LNN 비교 기준
비지도 이상탐지	PyOD 앙상블 (lForest·LOF·COPOD·ECOD)	pyod	라벨 외 패턴의 다변량 이상치 보조 스코어
네트워크 분석	NetworkX 이분 그래프	networkx	산업×고용형태 고위험 클러스터 식별
결과 시각화	Streamlit + Plotly	streamlit, plotly	정책 사용자용 대시보드

본 공모의 AI 활용은 **아이디어 자체의 구성 요소**로서의 AI를 의미한다. 본 아이디어는 위 모델군(머신러닝·딥러닝·이상탐지)이 **데이터 → 위험 스코어 → 우선순위**의 핵심 변환을 담당한다. (제안서 작성 보조용 LLM 사용 여부는 별도이며, 이는 시스템 구성 AI에 포함되지 않는다.)

3-2. 라벨 누수 방지·외부 검증 (심사 신뢰성 보강)

본 시스템의 AI는 단순 분류기가 아니라, 데이터 약지도(weak supervision) 한계까지 정면으로 다루는 검증 구조를 갖는다.

- 데이터 누수(leakage) 차단: 라벨 정의에 사용된 4대보험 가입 변수는 XGBoost 입력 피처에서 제외 (utils/real_data_processor.py 의 build_ml_features 참조).
- 이중 라벨:
 - ① 법정 기준 3-Condition Rule(4대보험·최저임금·초과근무).
 - ② 위크피디아 직종 임금 분포 기반 "직종 표준 미달"(예: 산업·직종별 P25 미만)을 보조 라벨로 결합.
- 외부 그라운드 트루스 검증: 임금체불 사업주 명단·연도별 근로사건 현황·노동포털 임금체불 통계와 산업·지역·연도 단위에서 매칭하여, 위험 상위 K%의 Precision@K / Recall@K를 보고한다. → 모델 점수의 정책 활용 가치를 외부 데이터로 정량화.
- 이주노동자 결합: 한국고용정보원 외국인근로자 근무현황으로 산업×지역×체류자격 외국인 비중을 산출, 위험 점수에 가중치로 결합 → 이주노동자 표적성 회복.

3-3. AI 활용의 지속성·활용범위·확장성

- 지속성: 위 데이터 모두 연·월 단위 정기 공표되며, 동일 파이프라인을 매년 재학습한다. 모델·임계값·평가 결과는 자동 저장 (results/).
- 활용범위:
 - 고용노동부 근로감독: 산업·지역·고용형태별 점검 우선순위 리스트.
 - 이주노동자 지원기관: 고위험 클러스터 선제 안내·통역 지원 우선 배정.
 - ESG·노무 컨설팅: 공급망 노동 리스크 평가의 객관적 보조 지표.
- 확장성:
 - 설명 가능성 — XGBoost feature importance, LNN attention 분석.
 - 실시간성 — EPS·고용24·신고 데이터와 결합 시 이벤트 트리거 기반 경보로 확장.
 - 사회적기업·근로복지공단·산업안전보건공단 데이터와 결합한 노동·안전 통합 위험지수로 확대.

3-4. 핵심 모델 — 왜 LNN인가

- 임금 지급은 간격이 불규칙(정상 사업장은 월 1회 규칙적, 착취 사업장은 지연·간헐). LSTM은 등간격을 가정하지만, LNN(CfC)은 시간 간격을 연속시간 ODE의 파라미터로 직접 다루 **간격 자체를 신호**로 학습한다.
- 본 저장소의 실험에서 3개월 시퀀스의 조기 탐지 AUROC가 LNN 0.9957 / LSTM 0.9900, 수렴 속도는 LNN이 LSTM 대비 약 25% 빠름으로 확인되었다.

4) 아이디어의 상세 설명(실용성)

4-1. 시스템 개요(작동 방식)

[입력 1] 주최·주관 공공데이터	[입력 2] 보조: 통계청 MDIS
고용노동부: 임금체불 명단 / 근로사건 / 임금체불 통계 / 고용 형태별근로실태조사(개방판) 한국고용정보원: 외국인근로자 근무현황(이주노동자 가중치) / EIS 고용행정통계 / 위크피디아 임금분포	고용형태별근로실태(미시) / 이민자체류-E9·근로환경 개인 식별 변수 미사용

1단계 — 전처리 · 라벨링

① 법정 3-Condition Rule (4대보험·최저임금·초과근무) ② 직종 표준 미달 (위크피디아 P25 미만) ③ 외부 그라운드 트루스 (임금체불 명단·근로사건)

2단계 — AI 위험 스코어링 (양상블)

• XGBoost 횡단면 위험 확률 • LNN / LSTM 시계열 조기 신호(불규칙 간격) • PyOD 양상블 비지도 이상 패턴 • 외국인 비중 가중치(외국인근로자 근무현황)

3단계 — 정책 사용자 대시보드 (Streamlit)

• 산업·지역·고용형태·연도별 위험 지도 • 점검 우선순위 리스트(설명·증빙 변수 포함) • 이주노동자 취약성 패널 • 외부 검증: Precision@K / Recall@K

근로감독 우선순위 / 이주노동자 지원 우선 배정

4-2. 주요 기능

#	기능	입력	출력	사용자
1	착취 라벨 생성	MDIS 변수	라벨(A/B/C/합집합)	분석가
2	횡단면 위험 모델	임금·근로·산업·규모·고용형태	사업장 단위 위험 확률	근로감독
3	시계열 조기 경보	월·분기 임금 시계열	위반 발생 사전 점수	근로감독·지원기관
4	이상 패턴 탐지	다변량 피쳐	비지도 이상 점수	분석가
5	이주노동자 보정	이민자·E9 조사	산업·고용형태별 취약 가중치	지원기관·정책
6	대시보드	결과 산출물	우선순위·지도·설명	근로감독·정책결정

4-3. 핵심 기술 요약


- 3-Condition Rule(법정 근거):
 - A. 4대보험 미가입(고용·건강·국민연금) — 법정 의무 위반.
 - B. 시간당임금 = 정액급여액 / 소정실근로시간 < 연도별 최저임금(8,590~9,860원, 2020~2024).
 - C. 초과실근로시간 ≥ 20h 이면서 초과급여액 = 0 — 근로기준법 제56조 위반 의심.
- 이중 라벨: 위크피디아 직종 임금 분포 대비 P25 미만을 직종 표준 미달 보조 라벨로 추가.
- 외부 검증: 위험 상위 K%를 임금체불 사업주 명단·근로사건 현황과 산업·지역 단위에서 매칭하여 Precision@K / Recall@K 산출.
- 이주노동자 가중치: $\text{risk_score}' = \text{risk_score} \times (1 + \alpha \times \text{외국인비중_산업_지역})$ — α 는 검증 데이터로 보정.
- 누수 방지(Leakage Control): XGBoost 피쳐에서 라벨 산출에 직접 사용된 4대보험 가입 변수는 제외(build_ml_features 참조).
- 불규칙 시계열 처리: LNN(CfC)으로 시간 간격을 연속시간 ODE 입력으로 사용.
- 설명 가능성: 위험 점수와 함께 상위 기여 변수 표시(예: 시간당임금, 초과수당지급비율, 4대보험 점수, 사업체규모, 고용형태 위험).
- 재현 가능성: 단일 명령으로 학습·평가·시각화가 재현됨.

```
pip install -r requirements.txt
python models/train_pipeline.py --quick --sample 0.03
streamlit run dashboard/app.py
```

4-4. 화면 예시 및 실증 시각화 (포함 이미지)

본 시스템은 이미 작동하는 실증 파이프라인을 갖추고 있으며, 본 제안서에서는 위험의 원인·시계열 미세 변화·점검 효율·상대 위험 지도 4축으로 핵심 산출을 시각화한다(저장소 `results/` 디렉터리 동봉). 모든 라벨은 시각 일관성을 위해 영문 표기한다.


[그림 1] 설명 가능한 위험 스코어링 — 어떤 사업장을 왜 위험하다고 보았는가



(a)는 실제 데이터 5-Fold 학습(n=240,204)에서 도출된 전역 변수 중요도다. 사회보험 점수(47.6%), 시간당임금(11.0%), 사업체 규모(8.8%), 고용 위험(8.2%) 순으로, 노동행정 담당자의 직관과 비교적 잘 맞는 순서다. (b)(c)(d)는 위험도가 다른 세 사업장(H 0.94 / M 0.55 / L 0.10)에 대해 변수별 +/- 기여도를 SHAP 방식으로 분해한 것으로, 한 사업장에 대해 "왜 위험하다고 봤는지"를 변수 단위로 확인할 수 있다. 점검 항목 우선순위를 바로 정할 수 있어, 모델 출력이 행정 처분의 보조 근거로 쓰일 수 있는 형태다.

[그림 2] 불규칙 임금 시계열에서의 조기 탐지 — LNN과 LSTM 비교

Figure 2. Irregular Wage Time Series Detection — LNN's Signature Advantage




(a)는 정상 사업장(30일 주기·정액 지급)과 의심 사업장(25~60일 불규칙 간격·금액 변동)의 임금 지급 시계열이다. (b)는 동일 케이스에서 LNN과 LSTM의 경보 시점 차이를 보여주는데, LNN은 6개월차에, LSTM은 10개월차에 경보를 띄웠다. (c)에서 1,000건의 시뮬레이션을 누적해 보면 LNN이 LSTM보다 평균 약 23일 일찍 위반 신호를 잡는다.

정상 사업장은 LSTM도 충분히 잡을 수 있지만, 임금이 조금씩 늦어지고 깎여 가는 미세한 패턴은 시간 간격을 직접 입력으로 받는 LNN에서 더 잘 드러난다. 약 3주의 시차는 이주노동자 한 사람 기준으로 한 달치 임금 손실을 줄일 수 있는 시간이며, 신고가 들어오기 전 단계에서 행정이 개입할 수 있는 여지를 만든다.

[그림 3] 점검 효율 — 동일 인력으로 얼마나 더 많이 적발하나


Figure 3. Inspection Efficiency — Same labor inspector budget, ~7x more violations caught



(a)는 누적 적발률 곡선이다. 위험 상위 5% 점검 시 위반의 50%, 상위 10%에서 67%, 상위 20%에서 85%가 잡힌다. (b)는 무작위 점검 대비 효율 막대로, Top 10%에서 7.2배, Top 20%에서도 여전히 4.6배다. 같은 점검 예산으로 적발률이 약 7배가 되거나, 같은 적발 성과를 1/7 인력으로 달성한다는 뜻으로, 감독관 1인당 사업장 수천 개라는 자원 한계에 직접 답하는 결과다. 다음 절(§6-3)의 행정 효율 환산과 같은 메시지를 시각으로 보여주는 그림이기도 하다.

[그림 4] 산업×지역 위험 지도 — 어디부터 점검할 것인가

Figure 4. Industry × Region Risk Map — Where to Inspect First



산업 8개와 지역 6개를 교차한 격자에 각 셀의 위험 점수가 국가 평균에서 얼마나 벗어났는지(σ 단위)를 표시한 그림이다. 농축산·경남(+1.6 σ), 소형 제조·충남(+1.4 σ), 농축산·충남(+1.3 σ) 등 상위 5개 클러스터가 색·테두리·별 표시로 자연스럽게 드러나며, 우측 패널에는 각 클러스터의 지배적 위험 요인(외국인 비중·시간당 임금·4대보험 점수)이 따로 정리된다. 정책 담당자가 "어느 업종·어느 지역부터 볼지"를 별도 분석 없이 한 화면에서 판단할 수 있도록 돕는 보조 도구다.

위 이미지는 본 시스템의 파이프라인 결과를 기반으로 scripts/build_proposal_figures.py 가 자동 생성한다. (a) 패널의 변수 중요도 등 핵심 수치는 results/pipeline_results.json 의 실제 학습 결과이며, (b)(c)(d) 사례-시뮬레이션은 정책적 의미 전달을 위한 대표 시나리오로, 실 운영 시 임금체불 명단-근로사건 매칭으로 정확함이 산출된다.

4-5. 사용자 시나리오

본 시스템의 가치는 두 사용자 군의 일상 업무에서 가장 분명하게 드러난다.

■ 시나리오 ① — 지방고용노동청 근로감독관 J 주무관 (월요일 09:00)

- 1. 대시보드 접속 → 「위험 상위 50개 사업장」리스트 자동 생성. 각 사업장에 AI 위험 점수 + 상위 기여 변수(예: "시간당임금 9,200원, 이주노동자 비중 38%, 4대보험 점수 0.31")가 함께 표시.
- 2. 외부 그라운드 트루스 패널에서 해당 산업·지역의 임금체불 명단-근로사건 발생 추세를 동시 확인 → 위험 상위 K%의 Precision@K가 78임을 보고, 점검 효율의 객관적 근거 확보.
- 3. 점검 대상 10개 선정 → 점검 통보·증빙 변수 자동 PDF 출력 → 현장 점검 시 즉시 활용. 점검 결과는 다시 학습 파이프라인으로 환류(인간 라벨 보강).

■ 시나리오 ② — 이주노동자 지원 NGO 통역사 N 활동가 (수요일 14:00)

- 1. 대시보드의 「이주노동자 취약성 패널」에서 자기 지역(○○시) 내 외국인 비중 30% 이상 + 위험 점수 상위 20% 사업장 12개를 자동 추출.
- 2. 각 사업장에 대한 언어별 안내문(베트남어·태국어·캄보디아어 등) 템플릿이 자동 생성됨 → 사전 방문·통역 지원 일정 확정.
- 3. 점검 후 결과(체불 청산·시정·계약 재작성 여부)를 시스템에 입력 → 다음 분기 모델이 NGO 개입 효과까지 반영한 위험 점수로 갱신.

이러한 시나리오를 통해 본 시스템은 데이터 → AI 점수 → 정책 행위 → 환류 학습의 폐쇄 루프를 가지며, 신고 의존 구조의 한계를 직접 보완한다.

5) 아이디어의 독창성(창의성)

- 1. 기존 부정수급 탐지 시스템과의 근본적 차이
 - 고용보험 부정수급 AI 등 기존 시스템은 사업주가 신고·신청한 행정 데이터의 모순을 탐지한다. WageGuard는 신고 자체가 발생하지 않는 임금·근로 마이크로데이터의 이상 패턴에서 위험을 찾는다. 탐지 대상(착취 의심 vs. 부정수급)과 데이터 계층(미시 근로실태 vs. 행정 신고)이 근본적으로 다르다. - 고용노동부·고용정보원 공식 개방 데이터 + 통계청 MDIS를 결합하여 외부 그라운드 트루스(임금체불 명단-근로사건) 검증까지 한 번에 수행한 구조는 국내 선례가 없다.
- 2. 법정 기준 3-Condition Rule + 직종 표준 미달 이중 라벨
 - 4대보험·최저임금·초과근무 + 워크피디아 직종 임금 분포 대비 P25 미만 = 주관 판단 배제 라벨 체계.
- 3. 불규칙 시계열에 LNN을 도입한 임금·근로 영역 최초 적용
 - LNN(CfC)으로 임금 지급 간격의 불규칙성 자체를 신호로 학습한다.
- 4. 이주노동자 표적성 회복
 - 외국인근로자 근무현황(고용정보원) × 이민자체류실태(MDIS) 결합으로 산업·지역·체류자격 수준 위험 가중치 산출.
- 5. 정책 행위로 환원되는 산출 형식
 - 단순 분류 결과가 아닌, 점검 우선순위 리스트·지도·설명으로 제공.
- 6. 윤리·인권 설계 내장
 - 자동 처벌 금지·결과 설명·개인 비식별·점검 보조 사용을 시스템 정의에 포함.

6) 아이디어 결과물의 성과 및 기대효과(효과성)

6-1. As-Is vs To-Be

영역	As-Is (현재)	To-Be (도입 후)
탐지 트리거	피해자 신고 의존 (5% 미만)	공공데이터 신호로 선제 점검
점검 우선순위	진정·민원·언론 보도 중심	AI 위험 점수 기반 우선순위
이주노동자 보호	사후 구제 중심	고위험 사업장 사전 안내·통역 지원
근로감독 효율	1인 수천 사업장, 수동 선별	위험 상위 N% 표적 점검
정책 평가	사후 통계 보고	연도 단위 변화·정책 효과 정량 측정
공급망 ESG	자기 보고 의존	데이터 기반 노동 리스크 스코어

6-2. 정량 기대 효과 (저장소 실증치 + 외부 검증)

이 표는 본 저장소에서 실제로 학습·평가되어 산출된 수치와, 외부 검증으로 확장될 지표를 함께 정리한 것이다.

지표	결과/계획	의미
분석 데이터 규모	491만 6,667건 (2020~2024)	신고 데이터 대비 수십~수백 배
실측 착취 비율	6.7% (3-Condition 합집합)	4대보험 5.4% / 최저임금 1.4% / 초과근무 0.1%
XGBoost 5-Fold AUROC	0.9998 ± 0.0001	횡단면 위험 모델의 변별력
LNN 3개월 조기 AUROC	0.9957 (LSTM 0.9900)	시계열 조기 신호의 우위
LNN 수렴 속도	LSTM 대비 약 25% 빠름	운영·재학습 비용 절감
E9 계약 미인지율	66.1%	신고 의존 한계의 구조적 근거
외부 검증 Precision@K / Recall@K	임금체불 명단·근로사건 현황과 산업·지역 단위 매칭하여 정량 보고(파이프라인 내장)	모델 출력의 정책 활용 가치 정량화

6-3. 점검 효율 환산 — 같은 인력으로 얼마나 더 적발하나

전체 사업장을 무작위로 뽑아 점검할 때 평균 적발률은 6.7%(3-Condition Rule 합집합)다. WageGuard의 위험 상위 10% 사업장에 점검을 집중할 때 Precision@10%를 보수적으로 45~50%로 가정하면, 같은 인력 투입에서 다음과 같은 차이가 난다.

운영 시나리오	점검 사업장	적발 사업장(추정)	효율
As-Is 무작위·민원 기반	1,000개	67개 (6.7%)	기준값
To-Be WageGuard 위험 상위 10%	100개	45~50개 (45~50%)	점검당 적발률 약 7배
동일 적발(67개) 달성 시 인력 비교	약 134~150개	67개	점검 인력 약 85~87% 절감

같은 적발 성과를 약 1/7 인력으로 달성하거나, 같은 인력으로 약 7배의 위반을 적발할 수 있다는 뜻이다. 근로감독관 1인당 사업장 수천 개라는 자원 한계를 직접 완화하는 효과다. **(Precision@10% 보수 추정치는 AUROC 0.9998과 위반율 6.7% 분포에서 산출했으며, 실제 운영 단계에서는 임금체불 명단·근로사건 매칭으로 정확값을 다시 보고한다.)**

6-4. 사회적·정책적 효과

- 고용노동 문제 해결: 임금 체불·최저임금 위반·초과근무 미지급의 사후 구제 비용(상담·신고·소송·체불금 청산 등) 감소.
- 불편감 해소: 이주노동자가 언어·체류 위험 없이 보호받을 수 있는 선제적 행정 서비스 제공.
- 사회적 비용 절감: 점검 자원의 위험 표적화로 동일 인력으로 더 많은 위반 적발·시정 가능.
- 만족도 증대: 사업장 측에도 객관적·예측 가능한 점검 기준 제공으로 행정 신뢰 향상.
- 확장 시나리오:
 - B2G: 고용노동부 근로감독 우선순위 자동화.
 - B2B: 노무법인·ESG 컨설팅의 공급망 노동 리스크 평가.
 - 공익: 이주노동자 지원 NGO·통역 자원의 선제 배정.

6-5. 한계와 보완 계획

한계	보완
동일 개인 추적 불가(MDIS 비식별)	사업장·산업×지역 단위 집단 추적 + 행정 데이터 연계 시 보강
외국인 식별 변수 부족	고용정보원 외국인근로자 근무현황 결합으로 산업×지역×체류자격 가중치 산출
약한 지도학습(라벨이 변수 함수)	임금체불 명단·근로사건 현황 외부 검증, 위크피디아 직종 라벨 보조
조사 시점·표본 편향	매년 갱신·연도 비교로 추세 검증
모델 오탐(False Positive)	점검 우선순위 보조 용도로 한정, 인간 검토 후 처분 원칙

6-6. 수상 즉시 가동 가능 — 이미 작동하는 실증 파이프라인

이 제안은 아이디어 부문으로 출품했지만, 통상 PoC 단계에 해당하는 코드·데이터·대시보드가 이미 갖춰져 있다.

항목	상태
데이터 수집·전처리 코드	공개 저장소에서 작동 (github.com/kts6450/WageGuard)
학습·평가 파이프라인	python models/train_pipeline.py 단일 명령 재현
정책 사용자 대시보드	Streamlit dashboard/app.py 즉시 실행
외부 검증 메커니즘	임금체불 명단·근로사건 매칭 자동화
라이선스·재현성	공개 코드, 의존성 명시(requirements.txt)

수상 후 별도 개발 기간 없이 다음 절(\$6-7)의 1단계(M+1~3) 외부 검증부터 곧바로 착수할 수 있어, 일반 아이디어 출품작이 PoC 단계에 진입하는 데 보통 드는 3~6개월 정도를 절약한다.

6-7. 단계적 실증 로드맵 (실현 가능성)

수상 후에는 이미 작동하는 파이프라인 위에서 다음 3단계로 실증을 확장할 계획이다.

단계	기간(누적)	핵심 활동	사용 데이터·기관	산출물
1단계 — 외부 검증·고도화	M+1 ~ M+3	① 임금체불 명단·근로사건 매칭 → Precision@K / Recall@K 정량 보고 ② LNN 누수 재검증 ③ 임계값·가중치 α 보정	고용노동부 임금체불 명단·근로사건 / 한국고용정보원 외국인근로자 근무현황	검증 리포트 v1.0, 모델 카드(Model Card)
2단계 — 광역 시범 적용	M+4 ~ M+6	① 1개 광역 지자체·고용노동지청과 협력 ② 위험 상위 50~100개 사업장 사전 점검 ③ 점검 결과 입력 → 모델 환류(능동 학습)	고용노동부 노동포털-EIS / 시범 지청 점검 결과	시범 적용 보고서, 사용자 매뉴얼(근로감독관·NGO용)
3단계 — 전국 확산·시스템 연계	M+7 ~ M+12	① 노동포털·EPS·고용24 시스템 연계 인터페이스 정의 ② 이주노동자 지원기관 4~6곳 연동 ③ 자동 재학습 스케줄러 운영	전체 주최·주관·후원 데이터 + EPS API	전국 운영 가이드, REST API 사양, 정책 의사결정 보고서

운영 지속성 보장 장치: 모든 입력 데이터는 연·월 단위 정기 공표이므로, 동일 파이프라인을 매년 자동 재실행하여 모델·임계값·외부 검증 결과를 갱신한다. 데이터 또는 라벨 분포의 분기별 **드리프트(drift)**가 임계치 초과 시 자동 알림 및 재보정.

[보충] 종합 및 실증 상태 (양식 외 별도 제목 — 공모 안내 “제시 목차 외 추가 내용”에 따라 기재)

본 아이디어 **WageGuard**는 ① 고용노동부·한국고용정보원의 공식 개방 공공데이터를 핵심으로 사용하고, ② 통계청 MDIS 마이크로데이터로 **법정 기준 라벨**을 정밀화하며, ③ XGBoost·LNN·PyOD를 결합한 **AI 위험 스코어링**과 **외부 그라운드 트루스 검증**(임금체불 명단·근로사건)을 통해, 신고 이전 단계의 **이주노동자 임금 착취**를 **선제적으로 탐지**한다. 결과는 자동 처벌이 아닌 **근로감독·지원 자원의 우선순위 제안**으로 환원되어, 같은 행정 자원으로 더 많은 위반을 적발·시정하고 더 많은 이주노동자를 보호할 수 있다.

이 출품작은 아이디어 부문으로 제출되었지만, 통상 PoC 단계의 산출물(491만 건 학습 데이터, XGBoost AUROC 0.9998, LNN 조기 AUROC 0.9957, 작동하는 Streamlit 대시보드, 공개 저장소)을 이미 갖췄다. 수상 후 별도 개발 기간 없이 정책 검증과 시범 적용에 곧바로 착수할 수 있으며, 고용노동부의 정책 방향인 노동 약자 보호·미조직 근로자 지원·찾아가는 행정을 데이터와 AI 인프라로 구현하는 한 가지 구체적 방식이다.

[보충] 부록 A. 관련 자료 (양식 외 별도 제목)

- 저장소: <https://github.com/kts6450/WageGuard>
- 핵심 코드: `utils/real_data_processor.py`, `models/train_pipeline.py`, `models/lnn_model.py`, `experiments/lnn_vs_lstm_experiment.py`, `dashboard/app.py`
- 결과 산출물: `results/pipeline_results.json`, `results/lnn_experiment_summary.json`, `results/lnn_vs_lstm_experiment.png` 등
- 데이터/AI 자가점검 메모: `CONTEST.md`
- 기술 보고서(논문 초안): `PAPER_DRAFT.md`
- 공모 정보: <https://www.2026datacontest.co.kr>

[보충] 부록 B. 주요 참고 문헌 (양식 외 별도 제목)

- Hasani et al., **Liquid Time-constant Networks**, AAAI 2021
- Hasani et al., **Closed-form Continuous-time Neural Networks**, Nature Machine Intelligence 2022
- Liu, Ting, Zhou, **Isolation Forest**, ICDM 2008
- Zhao, Nasrullah, Li, **PyOD: A Python Toolbox for Scalable Outlier Detection**, JMLR 2019
- Chen & Guestrin, **XGBoost: A Scalable Tree Boosting System**, KDD 2016
- ILO, **Global Estimates of Modern Slavery**, 2022
- 통계청, **고용형태별근로실태조사**, 2020–2024 (MDIS)
- 통계청, **이민자체류실태 및 고용조사**, 2021–2025 (MDIS)
- 고용노동부, **외국인근로자 고용 현황**, 2024
- 최저임금위원회, **연도별 최저임금 결정 현황**, 2024